Majeure Science des données

UP APRENTISSAGE STATISTIQUE

Liseth PASAGUAYO
liseth.pasaguayo@emse.fr, Bureau 524

20 octobre 2026

Analyse multivariée et méthodes factorielles

L'**analyse multivariée** regroupe des méthodes permettant d'étudier simultanément plusieurs variables observées sur un ensemble d'individus.

Méthodes factorielles

Elles cherchent à fournir une **représentation synthétique** de données multidimensionnelles dans un espace de **faible dimension**, tout en conservant autant que possible l'information contenue dans les données.

Parmi les principales méthodes factorielles :

ACP

Analyse en composantes principales

AFC

Analyse factorielle des correspondances

ACM

Analyse des correspondances multiples

Prérequis

Pour aborder l'Analyse Factorielle des Correspondances, quelques notions de **statistique** et d'**algèbre linéaire** seront utiles.

Statistique

- **Effectifs et fréquences**

$$f = \frac{n_{\text{obs}}}{n}$$

- **Distributions marginales** et conditionnelles
- **Indépendance** entre deux variables qualitatives

$$P(A \cap B) = P(A)P(B)$$

- Principe du **test du** χ^2 d'indépendance

Algèbre linéaire

- **Vecteurs et matrices**
- Opérations matricielles :

$$X^\top, \qquad Xu, \qquad AB$$

- **Norme et distance**
- Notion de **décomposition matricielle**
- Principe de la **décomposition en valeurs singulières**

$$Z = U\Sigma V^\top$$

Références bibliographiques

Support pédagogique de référence

- **Pagès, J. et Husson, F.** (2016). *Analyse factorielle des correspondances (AFC)*. Support de cours, Laboratoire de mathématiques appliquées, Agrocampus Rennes.

Pour approfondir le cours

- **Greenacre, M.** (2017). *Correspondence Analysis in Practice* (3e éd.). Chapman & Hall/CRC. DOI : 10.1201/9781315369983.
- **Lebart, L., Morineau, A. et Piron, M.** (1995). *Statistique exploratoire multidimensionnelle*. Dunod.

Ces références permettent de retrouver les notions présentées en cours et d'approfondir les aspects géométriques et mathématiques de l'AFC.

L’AFC

Plan du cours

1 Données et la notion d'indépendance

2 Profils et géométrie du χ^2

3 Analyse factorielle et interprétation

4 Application

1. Données et la notion d'indépendance

Quel type de données ?

Les données sont organisées dans un **tableau de contingence** : les lignes correspondent aux **modalités d'une première variable qualitative** et les colonnes aux **modalités d'une seconde variable qualitative**.

Exemple 1 : Situation familiale et origine de l'automobile

Situation familiale	Américain	Européen	Japonais	Total
Marié	37	14	51	102
Marié avec enfants	52	15	44	111
Célibataire	33	15	63	111
Célibataire avec enfants	6	1	8	15
Total	**128**	**45**	**166**	**339**

AFC : tableau de contingence = **modalités d'une variable qualitative** $\times$ **modalités d'une autre variable qualitative**

Quel type de données ?

Exemple 2 : Préférences musicales selon le groupe d'âge

Type de musique	Jeunes	Âge moyen	Âgées	Total
Musique disco	70	0	0	70
Rock'n'roll et musique américaine	45	45	0	90
Pop et musique anglaise	30	30	30	90
Jazz et musique autochtone	0	80	20	100
Musique classique	35	5	10	50
Total	**180**	**160**	**60**	**400**

Questions

- Quels types de musique sont globalement les plus populaires, et lesquels sont les moins choisis ?
- Existe-t-il une **relation entre le groupe d'âge** (jeunes, âge moyen, personnes âgées) et le **type de musique préféré** ?

Quel est le problème ?

Dans les deux exemples précédents, on étudie simultanément **deux variables qualitatives**.

Variable qualitative 1		**Variable qualitative 2**
Situation familiale	$\longleftrightarrow$	Origine de l'automobile
Groupe d'âge	$\longleftrightarrow$	Préférence musicale

Question centrale

Existe-t-il une **liaison entre les deux variables qualitatives** ou peut-on les considérer comme **indépendantes** ?

Lorsque le nombre de modalités augmente, la lecture directe du tableau de contingence devient plus difficile :

- quelles modalités sont associées ?
- quelles modalités présentent des profils similaires ?
- quelles sont les principales oppositions dans les données ?

Pourquoi réduire la dimension ?

Un tableau de contingence peut contenir un grand nombre de modalités et donc un grand nombre d'effectifs à analyser simultanément.

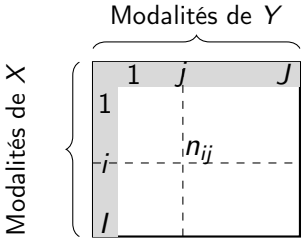
Plus le tableau est grand, plus sa structure devient difficile à interpréter directement.

On souhaite alors obtenir une représentation plus simple permettant de :

- **résumer** l'information contenue dans le tableau ;
- mettre en évidence les principales **associations entre les modalités** ;
- identifier des modalités ayant des **profils similaires ou opposés** ;
- **représenter graphiquement** ces relations dans un espace de faible dimension.

Analyse Factorielle des Correspondances (AFC)

L'AFC est une méthode exploratoire multidimensionnelle permettant de décrire et de synthétiser les liaisons entre **deux variables qualitatives** à partir d'un tableau de contingence.



$$N = \begin{pmatrix} n_{11} & n_{12} & \cdots & n_{1J} \\ n_{21} & n_{22} & \cdots & n_{2J} \\ \vdots & \vdots & \ddots & \vdots \\ n_{I1} & n_{I2} & \cdots & n_{IJ} \end{pmatrix} \in \mathbb{N}^{I \times J}$$

tableau de contingence
= tableau des effectifs croisés

I = nombre de modalités de X,

J = nombre de modalités de Y.

n_{ij} = effectif observé pour $X = i$ et $Y = j$.

Objectifs de l'AFC

- **Décrire – explorer :** les liaisons entre les modalités des deux variables qualitatives.
- **Synthétiser :** réduire la dimension et représenter les principales associations.

Un exemple fil rouge : que deviennent les bacheliers ?

On étudie la **destination après le bac** de 100 étudiants selon le **baccalauréat obtenu**.

Baccalauréat	Université	Classes prépa	Autres	Total
A	13	2	5	**20**
BDD'	20	2	8	**30**
CE	10	5	5	**20**
FGH	7	1	22	**30**
Total	**50**	**10**	**40**	**100**

X = baccalauréat obtenu ($I = 4$) $\qquad$ Y = destination après le bac ($J = 3$)

Questions

- La destination semble-t-elle **liée au baccalauréat obtenu** ?
- Que devrait-on observer si X et Y étaient **indépendantes** ?

Tableau de contingence et marges

Le tableau de contingence $N = (n_{ij})$ contient les **effectifs croisés** des deux variables qualitatives.

Bacc	Université	Prépa	Autres	$n_{i\cdot}$
A	13	2	5	**20**
BDD'	20	2	8	**30**
CE	10	5	5	**20**
FGH	7	1	22	**30**
$n_{\cdot j}$	**50**	**10**	**40**	**100**

$$N = (n_{ij}) \in \mathbb{N}^{I \times J}$$

Lecture : $n_{A,\text{Université}} = 13$, $n_{A\cdot} = 20$ et $n_{\cdot,\text{Université}} = 50$.

Effectif d'une case

$$n_{ij} = \text{effectif associé à } (X_i, Y_j)$$

Marges

$$\underbrace{n_{i\cdot} = \sum_{j=1}^{J} n_{ij}}_{\text{effectif marginal ligne}} \qquad \underbrace{n_{\cdot j} = \sum_{i=1}^{I} n_{ij}}_{\text{effectif marginal colonne}}$$

Effectif total

$$n = \sum_{i=1}^{I} \sum_{j=1}^{J} n_{ij} = 100$$

Des effectifs aux fréquences

Pour comparer les effectifs, on les rapporte à l'effectif total n :

$$\boxed{f_{ij} = \frac{n_{ij}}{n}} \quad \Longrightarrow \quad F = (f_{ij}), \qquad \sum_{i=1}^{I} \sum_{j=1}^{J} f_{ij} = 1.$$

$$f_{A,\text{Université}} = \frac{13}{100} = 0{,}13$$

13 % des étudiants sont issus du bac A et inscrits à l'université.

	Université	Prépa	Autres	$f_{i\cdot}$
A	0,13	0,02	0,05	**0,20**
BDD'	0,20	0,02	0,08	**0,30**
CE	0,10	0,05	0,05	**0,20**
FGH	0,07	0,01	0,22	**0,30**
$f_{\cdot j}$	**0,50**	**0,10**	**0,40**	**1**

Fréquences marginales

$$f_{i\cdot} = \underbrace{\frac{n_{i\cdot}}{n}}_{\substack{\text{fréquence marginale} \\ \text{ligne}}} \qquad f_{\cdot j} = \underbrace{\frac{n_{\cdot j}}{n}}_{\substack{\text{fréquence marginale} \\ \text{colonne}}}$$

Indépendance entre deux variables qualitatives

Deux variables qualitatives X et Y sont **indépendantes** si connaître X n'apporte aucune information sur Y.

Dans notre exemple
Si le baccalauréat et la destination sont indépendants : connaître le **bac obtenu** ne change pas la répartition des **destinations**.

Modèle d'indépendance

$$P(X = i, Y = j) = P(X = i)\,P(Y = j)$$

donc

$$\boxed{f_{ij}^{\text{ind}} = f_{i\cdot} f_{\cdot j}}$$

Probabilité conjointe = produit des **probabilités marginales**

Conséquence sur les distributions

$$\frac{f_{ij}^{\text{ind}}}{f_{i\cdot}} = f_{\cdot j} \qquad \frac{f_{ij}^{\text{ind}}}{f_{\cdot j}} = f_{i\cdot}$$

Fréquence conditionnelle = **fréquence marginale**

Bac A $\times$ Université :

$$f_{A,\text{Universit}}^{\text{ind}} = f_{A\cdot}\, f_{\cdot\text{Universit}} = 0{,}20 \times 0{,}50 = 0{,}10$$

Tableau attendu sous indépendance

Sous l'hypothèse d'indépendance, les fréquences attendues sont :

$$f_{ij}^{\text{ind}} = f_{i\cdot} f_{\cdot j} \iff n_{ij}^{\text{ind}} = \frac{n_{i\cdot} n_{\cdot j}}{n}$$

Effectifs observés

Bacc	Univ.	Prépa	Autres	$n_{i\cdot}$
A	**13**	2	5	20
BDD'	20	2	8	30
CE	10	5	5	20
FGH	7	1	22	30
$n_{\cdot j}$	50	10	40	100

Effectifs attendus

Bacc	Univ.	Prépa	Autres	$n_{i\cdot}$
A	**10**	2	8	20
BDD'	15	3	12	30
CE	10	2	8	20
FGH	15	3	12	30
$n_{\cdot j}$	50	10	40	100

$$n_{A,\text{Univ.}} = 13$$

$$n_{A,\text{Univ.}}^{\text{ind}} = \frac{20 \times 50}{100} = 10$$

Comment quantifier les écarts entre les effectifs observés et attendus ?

Écarts à l'indépendance

On compare les **effectifs observés** aux effectifs obtenus sous l'hypothèse d'indépendance :

$$e_{ij} = n_{ij} - n_{ij}^{\text{ind}}$$

Matrice des écarts

$$E = N - N^{\text{ind}} = \begin{pmatrix} 3 & 0 & -3 \\ 5 & -1 & -4 \\ 0 & 3 & -3 \\ -8 & -2 & 10 \end{pmatrix}$$

Par exemple :

$$e_{\text{FGH,Autres}} = 22 - 12 = \boxed{10}$$

$e_{ij} > 0$

plus d'individus qu'attendu

$e_{ij} < 0$

moins d'individus qu'attendu

$$\sum_{i=1}^{I} \sum_{j=1}^{J} e_{ij} = 0$$

Les écarts positifs et négatifs se compensent : **leur somme ne mesure pas la liaison.**

Mesurer l'écart à l'indépendance

Les écarts $e_{ij} = n_{ij} - n_{ij}^{\text{ind}}$ peuvent être positifs ou négatifs : leur somme ne permet donc pas de mesurer la liaison.

Distance du χ^2 à l'indépendance

$$\chi^2 = \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{\left(n_{ij} - n_{ij}^{\text{ind}}\right)^2}{n_{ij}^{\text{ind}}}$$

Chaque écart est :

- élevé au **carré** ;
- rapporté à l'**effectif attendu**.

Une case : FGH – Autres

$$n_{ij} = 22, \qquad n_{ij}^{\text{ind}} = 12$$

$$\frac{(22-12)^2}{12} = \frac{100}{12} \simeq 8{,}33$$

Cette case apporte environ **8,33 unités au χ^2 total**.
Plus cette contribution est élevée, plus la case participe à **l'écart global à l'indépendance**.

Comment passer du χ^2 à l'inertie en AFC ?

Du χ^2 à l'inertie

1. Passage aux fréquences

On sait que :

$$n_{ij} = n f_{ij}, \qquad n_{ij}^{\text{ind}} = n f_{i.} f_{.j}$$

En remplaçant dans le χ^2 :

$$\chi^2 = n \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{(f_{ij} - f_{i.} f_{.j})^2}{f_{i.} f_{.j}}$$

Le facteur n apparaît lors du passage aux fréquences.

2. Mesure Φ^2 de Pearson

On rapporte le χ^2 à l'effectif total n :

$$\Phi^2 = \frac{\chi^2}{n}$$

Φ^2 mesure l'écart global à l'indépendance à partir des fréquences.

$\Phi^2 = 0 \iff X$ et Y indépendantes.

En AFC, nous montrerons que Φ^2 correspond à l'inertie totale du nuage.

2. Profils et géométrie du χ^2

Profils-lignes

Un **profil-ligne observé** décrit la répartition de Y pour une modalité donnée X_i, à partir des effectifs observés.

Profil observé de la ligne i

$$p_{j|i} = \frac{f_{ij}}{f_{i.}} = \frac{n_{ij}}{n_{i.}}$$

$$\sum_{j=1}^{J} p_{j|i} = 1$$

	Univ.	Prépa	Autres
A	0,65	0,10	0,25
BDD'	0,67	0,07	0,27
CE	0,50	0,25	0,25
FGH	0,23	0,03	0,73

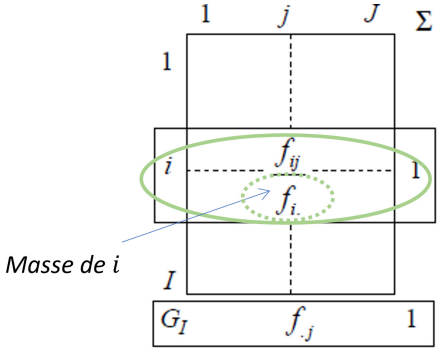
Chaque ligne somme à 1.

Exemple : bac A

$$\left(\frac{13}{20}, \frac{2}{20}, \frac{5}{20}\right) = (0{,}65;\ 0{,}10;\ 0{,}25)$$

Profil moyen des lignes

Fréquences conjointes et marginales



Masse de la ligne i

$$f_{i.} = \frac{n_{i.}}{n}$$

Profil moyen

Répartition globale de Y :

$$\boxed{G_I = (f_{.1}, \ldots, f_{.J})}$$

Dans notre exemple :

$$G_I = (0{,}50;\ 0{,}10;\ 0{,}40)$$

Sous indépendance

$$f_{ij}^{\text{ind}} = f_{i.} f_{.j} \quad \Longrightarrow \quad \frac{f_{ij}^{\text{ind}}}{f_{i.}} = f_{.j}$$

Tous les profils-lignes seraient alors **égaux à** G_I.

Nuage des profils-lignes

1. Un profil = un point

$$i \longmapsto p_i = \left(\frac{f_{i1}}{f_{i.}}, \ldots, \frac{f_{iJ}}{f_{i.}} \right) \in \mathbb{R}^J$$

2. Dimension

$$\sum_{j=1}^{J} p_{j|i} = 1$$

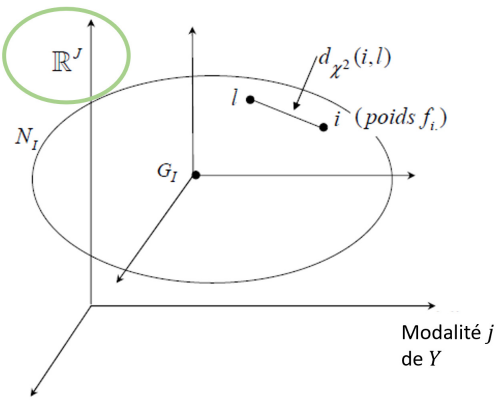
Dimension du sous-espace affine $= J - 1$

3. Masse et centre

Masse de i $m_i = f_{i.}$

$$G_I = \sum_{i=1}^{I} f_{i.} p_i = (f_{.1}, \ldots, f_{.J})$$

Nuage des I profils-lignes



Distance entre deux profils-lignes

Deux modalités i et i' de X sont proches si leurs **profils-lignes observés** sont proches.

Distance euclidienne

$$d^2_{\mathrm{E}}(i,i') = \sum_{j=1}^{J} \left(p_{j|i} - p_{j|i'}\right)^2$$

Elle donne le **même poids** à toutes les modalités j de Y.

Or leurs fréquences marginales $f_{\cdot j}$ peuvent être très différentes.

Distance du χ^2

$$d^2_{\chi^2}(i,i') = \sum_{j=1}^{J} \frac{1}{f_{\cdot j}} \left(p_{j|i} - p_{j|i'}\right)^2$$

À écart de profils égal, une modalité **rare** de Y reçoit un poids plus élevé dans la distance du χ^2.

Exemple :

$$G_I = (f_{\cdot 1}, f_{\cdot 2}, f_{\cdot 3}) = (0{,}50;\ 0{,}10;\ 0{,}40)$$

$$\left(\frac{1}{f_{\cdot 1}}, \frac{1}{f_{\cdot 2}}, \frac{1}{f_{\cdot 3}}\right) = (2;\ 10;\ 2{,}5)$$

Les écarts sur Prépa sont davantage pondérés.

Profils-colonnes

Un **profil-colonne observé** décrit la répartition de X pour une modalité donnée Y_j, à partir des effectifs observés.

Profil observé de la colonne j

$$p_{i|j} = \frac{f_{ij}}{f_{\cdot j}} = \frac{n_{ij}}{n_{\cdot j}}$$

$$\sum_{i=1}^{I} p_{i|j} = 1$$

	Univ.	Prépa	Autres
A	0,26	0,20	0,125
BDD'	0,40	0,20	0,20
CE	0,20	0,50	0,125
FGH	0,14	0,10	0,55

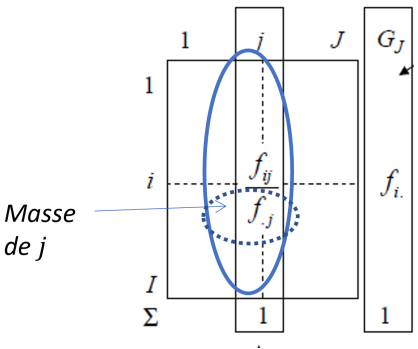
Chaque colonne somme à 1.

Exemple : Université

$$\left(\frac{13}{50}, \frac{20}{50}, \frac{10}{50}, \frac{7}{50}\right) = (0{,}26;\ 0{,}40;\ 0{,}20;\ 0{,}14)$$

Profil moyen des colonnes

Fréquences conjointes et marginales



Masse de la colonne j

$$f_{.j} = \frac{n_{.j}}{n}$$

Profil moyen

Répartition globale de X :

$$\boxed{G_J = (f_{1.}, \ldots, f_{I.})}$$

Dans notre exemple :

$$G_J = (0{,}20;\ 0{,}30;\ 0{,}20;\ 0{,}30)$$

Sous indépendance

$$f_{ij}^{\text{ind}} = f_{i.} f_{.j} \quad \Longrightarrow \quad \frac{f_{ij}^{\text{ind}}}{f_{.j}} = f_{i.}$$

Tous les profils-colonnes seraient alors **égaux à G_J**.

Nuage des profils-colonnes

1. Un profil = un point

$$j \longmapsto q_j = \left(\frac{f_{1j}}{f_{.j}}, \ldots, \frac{f_{Ij}}{f_{.j}} \right) \in \mathbb{R}^I$$

2. Dimension

$$\sum_{i=1}^{I} p_{i|j} = 1$$

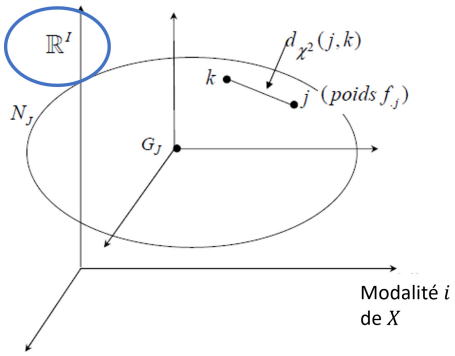
Dimension du sous-espace affine $= I - 1$

3. Masse et centre

Masse de $j = f_{.j}$

$$G_J = \sum_{j=1}^{J} f_{.j} q_j$$

Nuage des J profils-colonnes



Distance entre deux profils-colonnes

Deux modalités j et j' de Y sont proches si leurs **profils-colonnes observés** sont proches.

Distance du χ^2

$$d^2_{\chi^2}(j, j') = \sum_{i=1}^{I} \frac{1}{f_{i.}} \left(p_{i|j} - p_{i|j'}\right)^2$$

Interprétation

La distance compare la **composition des destinations** en types de baccalauréat.
À écart de profils égal, un type de baccalauréat **moins fréquent** reçoit un poids plus élevé.

Pondération :

$$\frac{1}{f_{i.}}$$

Dans notre exemple :

$$G_J = (0{,}20;\ 0{,}30;\ 0{,}20;\ 0{,}30)$$

$$\left(\frac{1}{f_{1.}}, \frac{1}{f_{2.}}, \frac{1}{f_{3.}}, \frac{1}{f_{4.}}\right) = (5;\ 3{,}33;\ 5;\ 3{,}33)$$

Les écarts sur A et CE sont davantage pondérés.

Inertie totale du nuage des profils

L'inertie mesure la **dispersion des profils** autour de leur centre de gravité.

Pour les profils-lignes

$$\mathcal{I} = \sum_{i=1}^{I} f_{i\cdot}\, d^2_{\chi^2}(p_i, G_I)$$

Chaque profil contribue selon :

$$\underbrace{f_{i\cdot}}_{\text{masse}} \times \underbrace{d^2_{\chi^2}(p_i, G_I)}_{\text{distance au centre au carré}}$$

Lien avec le χ^2

$$\mathcal{I} = \Phi^2 = \frac{\chi^2}{n}$$

Sous indépendance :

$$X \perp Y \implies \mathcal{I} = 0.$$

Plus les profils s'éloignent de leur centre, plus l'inertie totale est grande.

Même inertie totale pour les profils-colonnes :

$$\mathcal{I} = \sum_{j=1}^{J} f_{\cdot j}\, d^2_{\chi^2}(q_j, G_J)$$

3. Analyse factorielle et interprétation

Réduire la dimension

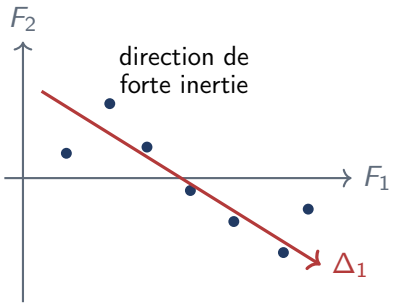
Les profils appartiennent à des espaces de dimension potentiellement élevée :

profils-lignes : $J - 1$ profils-colonnes : $I - 1$.

Objectif de l'AFC

Construire un espace de faible dimension qui conserve au mieux la **dispersion des profils**.

nuage initial $\longrightarrow$ axes factoriels



Les premiers axes sont choisis pour restituer le maximum d'inertie.

Combien d'axes factoriels ?

Les profils sont soumis à la contrainte que leurs coordonnées somment à 1 :

$$\dim(\text{profils-lignes}) = J - 1, \qquad \dim(\text{profils-colonnes}) = I - 1.$$

Le nombre maximal d'axes factoriels non triviaux est donc

$$\boxed{S \leq \min(I - 1, J - 1)}$$

ou, de manière équivalente,

$$\boxed{S \leq \min(I, J) - 1}$$

Dans notre exemple

$$I = 4, \qquad J = 3$$

$$S \leq \min(3, 2) = \boxed{2}.$$

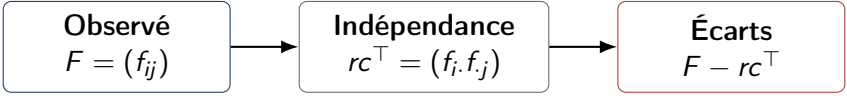
L'information factorielle peut donc être représentée sur au plus **deux axes**.

$$F_1 \qquad \text{et} \qquad F_2$$

Centrer autour de l'indépendance

En ACP, on étudie les écarts à la **moyenne**.
En AFC, on étudie les écarts à la situation d'**indépendance**. $F = (f_{ij})$.

$$r = \begin{pmatrix} f_{1\cdot} \\ \vdots \\ f_{I\cdot} \end{pmatrix}, \qquad c = \begin{pmatrix} f_{\cdot 1} \\ \vdots \\ f_{\cdot J} \end{pmatrix}$$



$$\boxed{(F - rc^\top)_{ij} = f_{ij} - f_{i\cdot} f_{\cdot j}}$$

Sous indépendance :

$$F = rc^\top \qquad \Longrightarrow \qquad F - rc^\top = 0.$$

La matrice analysée en AFC

L'AFC analyse les **écarts à l'indépendance**, en tenant compte des masses des lignes et des colonnes.

Écart à l'indépendance

$$f_{ij} - f_{i\cdot} f_{\cdot j}$$

Écart standardisé

$$\boxed{z_{ij} = \frac{f_{ij} - f_{i\cdot} f_{\cdot j}}{\sqrt{f_{i\cdot} f_{\cdot j}}}}$$

Si X et Y sont indépendantes :

$$f_{ij} = f_{i\cdot} f_{\cdot j} \quad \Longrightarrow \quad z_{ij} = 0.$$

Écriture matricielle

$$D_r = \mathrm{diag}(f_{1\cdot}, \ldots, f_{I\cdot})$$

$$D_c = \mathrm{diag}(f_{\cdot 1}, \ldots, f_{\cdot J})$$

$$\boxed{Z = D_r^{-1/2} \left(F - r\, c^\top \right) D_c^{-1/2}}$$

avec

$$r = (f_{1\cdot}, \ldots, f_{I\cdot})^\top, \qquad c = (f_{\cdot 1}, \ldots, f_{\cdot J})^\top.$$

Décomposition factorielle

On applique une **décomposition en valeurs singulières (SVD)** à la matrice des écarts standardisés :

$$Z = U \Sigma V^\top$$

Directions factorielles

$U = (u_1, \ldots, u_S)$ directions associées aux modalités-lignes

$V = (v_1, \ldots, v_S)$ directions associées aux modalités-colonnes

Valeurs singulières

$$\Sigma = \mathrm{diag}(\sigma_1, \ldots, \sigma_S), \qquad \sigma_1 \geq \cdots \geq \sigma_S \geq 0$$

$$\lambda_s = \sigma_s^2$$

λ_s : **inertie portée par l'axe** s

Décomposition de l'inertie totale

$$\mathcal{I} = \Phi^2 = \frac{\chi^2}{n} = \sum_{s=1}^{S} \lambda_s$$

Coordonnées factorielles

La SVD fournit les directions factorielles. Les masses permettent ensuite d'obtenir les **coordonnées des modalités** sur les axes.

$$Z = U\Sigma V^\top$$

Modalités-lignes

$$\boxed{F = D_r^{-1/2} U\Sigma}$$

La coordonnée de la modalité i sur l'axe s est :

$$\boxed{F_{is} = \frac{\sigma_s}{\sqrt{f_{i\cdot}}}\, u_{is}}$$

Modalités-colonnes

$$\boxed{G = D_c^{-1/2} V\Sigma}$$

La coordonnée de la modalité j sur l'axe s est :

$$\boxed{G_{js} = \frac{\sigma_s}{\sqrt{f_{\cdot j}}}\, v_{js}}$$

Ces coordonnées permettent de construire les cartes factorielles.

Dans ces formules, F et G désignent les matrices des coordonnées principales, et non la matrice des fréquences

Part d'inertie expliquée par un axe

Chaque axe factoriel s porte une inertie :

$$\boxed{\lambda_s = \sigma_s^2}$$

$$\mathcal{I} = \underbrace{\lambda_1}_{\text{axe } 1} + \underbrace{\lambda_2}_{\text{axe } 2} + \cdots + \underbrace{\lambda_S}_{\text{axe } S}$$

Quelle part de l'inertie totale est portée par l'axe s ?

$$\boxed{\tau_s = \frac{\lambda_s}{\mathcal{I}} = \frac{\lambda_s}{\sum_{\ell=1}^{S} \lambda_\ell}}$$

$100\,\tau_s$ est le **pourcentage d'inertie expliqué par l'axe** s.

Inertie expliquée par le plan factoriel

Les deux premiers axes définissent le **plan factoriel** $(1, 2)$.

Inertie totale

$$\mathcal{I} = \sum_{s=1}^{S} \lambda_s$$

$\longrightarrow$ **Plan** $(1, 2)$

$$\lambda_1 + \lambda_2$$

$\longrightarrow$ **Part conservée**

$$\boxed{\tau_{1,2} = \frac{\lambda_1 + \lambda_2}{\sum_{s=1}^{S} \lambda_s}}$$

$100\,\tau_{1,2}$ est le **pourcentage d'inertie représenté sur le plan** $(1, 2)$.

Dans notre exemple :

$$I = 4, \qquad J = 3 \qquad \Longrightarrow \qquad S \leq \min(I - 1, J - 1) = 2.$$

$$\boxed{\text{Si } S = 2, \qquad \tau_{1,2} = 1 \qquad \Longrightarrow \qquad 100\,\% \text{ de l'inertie est représentée.}}$$

Qualité de représentation : le $\cos^2$

Le $\cos^2$ mesure la **qualité de représentation** d'une modalité sur un axe factoriel.

Pour une modalité-ligne i

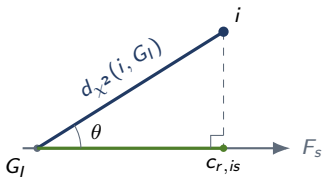
$$\cos^2(i,s) = \frac{c_{r,is}^2}{d_{\chi^2}^2(i,G_I)}$$

$$0 \leq \cos^2(i,s) \leq 1$$

Sur le plan $(1,2)$

$$\cos^2(i,1:2) = \cos^2(i,1) + \cos^2(i,2)$$

Interprétation géométrique



$$\cos^2(i,s) = \cos^2(\theta)$$

$\cos^2 \simeq 1 \Longrightarrow$ **bien représentée**

$\cos^2 \simeq 0 \Longrightarrow$ **mal représentée**

Contribution à un axe

La contribution mesure la **participation d'une modalité** à la construction d'un axe factoriel.

Pour une modalité-ligne i

$$\boxed{\text{ctr}(i,s) = \frac{f_{i\cdot}\, c_{r,is}^2}{\lambda_s}}$$

$\underbrace{f_{i\cdot}}_{\text{masse}} \times \underbrace{c_{r,is}^2}_{\text{éloignement sur l'axe}}$ rapporté à $\underbrace{\lambda_s}_{\text{inertie de l'axe}}$

$$\boxed{\sum_{i=1}^{I} \text{ctr}(i,s) = 1}$$

Contribution élevée

La modalité participe fortement à la **construction de l'axe**.

Contribution faible

La modalité participe peu à la **construction de l'axe**.

Cos^2 ou contribution ?

Deux indicateurs, **deux questions différentes**.

Cos^2

Qualité de représentation

Puis-je interpréter la position de cette modalité sur l'axe ?

cos^2 élevé

⇓

modalité **bien représentée**

Contribution

Construction de l'axe

Cette modalité participe-t-elle fortement à la définition de l'axe ?

Contribution élevée

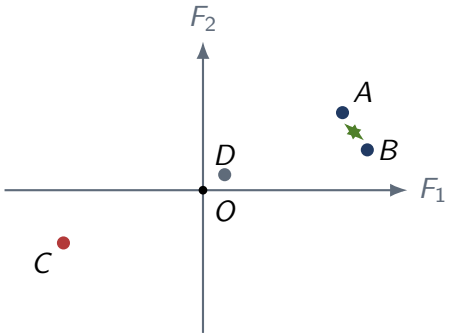
⇓

modalité **importante pour l'axe**

Bien représentée $\neq$ forte contribution

Comment lire une carte factorielle ?

Une carte factorielle représente les modalités à partir de leurs **coordonnées factorielles**.



Proches

$$A \approx B$$

Profils similaires.

Opposées

$$A \mid C$$

Profils contrastés sur l'axe.

Loin de l'origine

Profil éloigné du profil moyen dans le plan représenté.

Près de l'origine

Profil proche du profil moyen dans le plan représenté.

Interpréter lignes et colonnes ensemble

L'AFC permet de représenter les modalités de X et de Y sur un même plan factoriel.

Ce que l'on peut interpréter

Dans une même famille :

ligne $\leftrightarrow$ ligne ou colonne $\leftrightarrow$ colonne

La proximité traduit des **profils similaires**.

Entre lignes et colonnes :
une orientation similaire par rapport à l'origine peut suggérer une association, à confirmer par l'examen des profils et des écarts à l'indépendance.

Attention

La distance graphique entre une modalité-ligne i et une modalité-colonne j :

$$\boxed{d(i,j)}$$

n'est pas une distance du χ^2 entre les deux modalités.
On évite donc :

$$\boxed{\text{proches sur la carte} \Rightarrow \text{fortement associés}}$$

sans analyse supplémentaire.

On interprète d'abord les axes, puis les modalités qui les caractérisent.

Comment interpréter un axe factoriel ?

Un axe se construit à partir des modalités qui contribuent le plus à son inertie.

1
Repérer
les modalités à
forte contribution

→

2
Vérifier
leur qualité de
représentation : $\cos^2$

→

3
Caractériser
les deux côtés
de l'axe



Interpréter un axe = donner un sens à l'opposition entre ses deux pôles.

4. Application