TP2 : Arbre de décision et Foret aléatoire

Indications générales :

1. Le TP est un travail individul.
2. Le travail doit être démarré durant la séance de TP, à terminer chez soi pour être remis sur Campus avant le 8/11/2026 à 23h55.
3. Un compte rendu obligatoire en format PDF doit être soumis avant le 8/11/2026 à 23h55.
4. Aucun dépôt en retard n'est autorisé, et les envois par email ne seront pas acceptés.
5. Dans le compte rendu vous présentez le code utilisé pour résoudre chaque partie (dans le cas où le code n'est pas donné) ainsi que les résultats obtenus et l'interprétation détaillée des résultats le cas échéant.
6. L'évaluation est principalement sur votre capacité d'analyser, de critiquer et d'interpréter les résultats. Ainsi, il est essentiel d'expliquer clairement vos conclusions.
7. Vous êtes libre de coder en R, Python ou dans tout autre langage de programmation adapté au machine learning.

Problème I : Arbres de décision, une application sur des données réelles :

Dans cet exercice, il s'agit d'expérimenter une implémentation de l'arbre de décision pour un problème de classification binaire.

1. A partir du répertoire en ligne "Échantillons de données" (voir sur Campus), choisissez un échantillon de données. Commencez par effectuer une analyse exploratoire descriptive de votre base de données (typologie des variables, valeurs manquantes, distributions des observations pour les différentes variables, boxplots, etc.).
2. Utilisez une implémentation de l'arbre de décision sous R (ou autre) pour construire un classifieur ayant pour objectif de prédire la classe de la variable dépendante dans votre base de données après avoir observé les variables indépendantes, en respectant les consignes suivantes :

(a) Optimisez votre arbre de classification en passant par des techniques vues dans le cours (par exemple, l'optimisation des hyperparamètres par validation croisée, élagage, etc.).

(b) Selon le mode opératoire, visualisez l'arbre optimal généré.

3. Vous serez évalué sur les résultats de votre modèle optimal **appliqué aux données test** :

   (a) Explorer le résultat de la classification :

      i. Detailed Accuracy By Class (Precision, Recall,...)

      ii. Confusion Matrix

      iii. Etc. (Je vous invite à calculer autant de métriques de performance que possible tout en justifiant les résultats obtenus à chaque fois.)

   (b) Veuillez inclure dans le compte rendu la courbe ROC et l'AUC de votre modèle optimal.

   (c) Donnez une conclusion/interprétation globale par rapport aux résultats obtenus. N'hésitez pas à faire preuve de créativité et à aller au-delà des questions demandées. Toute idée d'analyse à valeur ajoutée sera fortement appréciée. ?

4. Enfin, comparez la performance de votre modèle avec un modèle de régression logistique classique, tel que développé dans le TD1, et interprétez les résultats.

Problème II : Foret aléatoire, une application sur des données réelles :

Dans cet exercice, il s'agit d'expérimenter une implémentation d'une forets aléatoires de décision.

1. A partir du répertoire en ligne "Échantillons de données" (voir sur Campus), considérez le même échantillon de données du problème I. Utiliser différentes implémentations (au moins deux) du foret aléatoire sous R et pour chaque implémentation présentez-moi avec clarté les étapes de votre raisonnement menant au modèle optimal (Out-of sample estimation, Cross Validation, Élagage, optimisation des hyperparamètres, etc.)

2. Analysez et comparez les performances des différentes implémentations des forêts aléatoires (partie 1) à l'aide des indicateurs de classification tels que la précision, le rappel, la matrice de confusion, les courbes ROC et l'AUC, etc. Interprétez le résultat.