Majeure Science des données

UP APRENTISSAGE STATISTIQUE

Liseth PASAGUAYO
liseth.pasaguayo@emse.fr, Bureau 524

14 octobre 2026

Analyse multivariée et méthodes factorielles

L'**analyse multivariée** regroupe des méthodes permettant d'étudier simultanément plusieurs variables observées sur un ensemble d'individus.

Méthodes factorielles

Elles cherchent à fournir une **représentation synthétique** de données multidimensionnelles dans un espace de **faible dimension**, tout en conservant autant que possible l'information contenue dans les données.

Parmi les principales méthodes factorielles :

ACP

Analyse en composantes principales

AFC

Analyse factorielle des correspondances

Prérequis

Pour aborder l'Analyse en Composantes Principales, quelques notions d'**algèbre linéaire** et de **statistique descriptive** seront utiles.

Algèbre linéaire

- **Vecteurs et matrices**
- Opérations matricielles :

$$X^\top, \qquad Xu, \qquad u^\top v$$

- **Interprétation géométrique** des vecteurs :
  - norme et distance ;
  - angle ;
  - projection orthogonale.
- **Valeurs propres et vecteurs propres**

$$Au = \lambda u$$

Statistique descriptive

- Mesures de tendance centrale :

  moyenne

- Mesures de dispersion :

  variance, écart-type

- **Covariance et corrélation**
- **Centrage et réduction** des variables

Références bibliographiques

Support pédagogique de référence

- **Husson, F.** (s. d.). *Analyse en composantes principales (ACP)*. Support de cours, Laboratoire de mathématiques appliquées, Agrocampus Rennes.

Pour approfondir le cours

- **Lebart, L., Morineau, A. et Piron, M.** (1995). *Statistique exploratoire multidimensionnelle*. Dunod.
- **Smith, L. I.** (2002). *A Tutorial on Principal Components Analysis*.
- **Wiskott, L.** (2013). *Lecture Notes on Principal Component Analysis*. Ruhr-Universität Bochum.

Ces références permettent de retrouver les notions présentées en cours et d'approfondir les aspects géométriques et mathématiques de l'ACP.

L’ACP

Plan du cours

1 Données et préparation

2 Étude des individus

3 Étude des variables

4 Application

1. Données et préparation

Quel type de données ?

Les données sont organisées dans une matrice X : les **individus** sont disposés en lignes et les **variables quantitatives** en colonnes.

Exemple 1 : Caractéristiques des automobiles

Automobile	Prix (€)	Puissance (CV)	Consommation (L/100 km)	Poids (kg)
Auto A	18 000	90	5,2	1 050
Auto B	22 000	120	6,1	1 180
Auto C	27 000	150	6,8	1 320
Auto D	32 000	180	7,5	1 450
Auto E	40 000	220	8,4	1 600
Auto F	48 000	260	9,1	1 720

ACP : tableau individus $\times$ variables quantitatives

Les données

Exemple 2 : Pollution atmosphérique dans 41 villes américaines

Ville	SO_2 ($\mu g/m^3$)	Temp. (°F)	Entreprises	Population (milliers)	Vent (mph)	Précip. (in)	Jours
Phoenix	10	70,3	213	582	6,0	7,05	36
Little Rock	13	61,0	91	132	8,2	48,52	100
Miami	10	75,5	207	335	9,0	59,80	128
Atlanta	24	61,5	368	497	9,1	48,34	115
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
Chicago	110	50,6	3344	3369	10,4	34,44	122

Individus : les villes **Variables :** les caractéristiques environnementales et urbaines

- Comment mesurer la ressemblance entre deux villes en tenant compte simultanément de plusieurs variables ?
- Comment représenter graphiquement l'ensemble des villes décrites par 7 variables ?

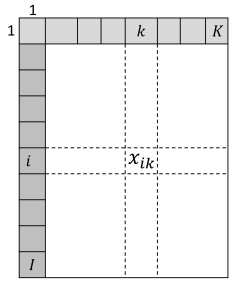
Un problème de dimension

$$\mathbb{R}^K \longrightarrow \mathbb{R}^q, \qquad q < K$$

- Est-ce possible ?
- Comment construire ces nouvelles dimensions ?
- Combien de dimensions faut-il conserver ?
- Quelle quantité d'information perd-on ?

Analyse en Composantes Principales (ACP)

L'ACP est une méthode exploratoire multidimensionnelle permettant de décrire et de synthétiser un tableau d'individus $\times$ variables quantitatives à l'aide d'un nombre réduit de dimensions.



$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1K} \\ x_{21} & x_{22} & \cdots & x_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ x_{I1} & x_{I2} & \cdots & x_{IK} \end{pmatrix} \in \mathbb{R}^{I \times K}$$

I = nombre d'individus,

K = nombre de variables,

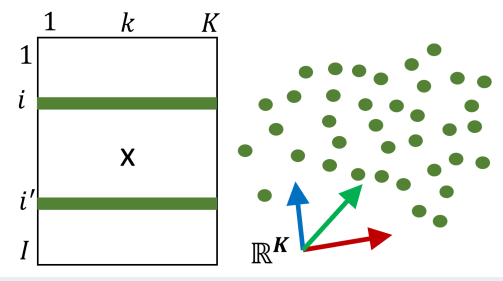
x_{ik} = valeur de l'individu i pour la variable k.

Objectifs de l'ACP

- Décrire – explorer : ressemblances entre individus et les liaisons entre variables
- Synthétiser : réduire la dimension et conserver l'essentiel de l'information

Deux nuages de points

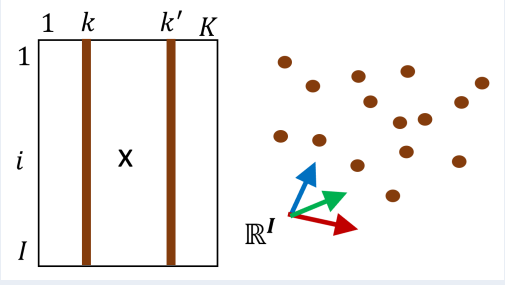
Etude des individus



Chaque **individu** i est représenté par un point dans l'espace des variables $\mathbb{R}^K$.

On étude les proximités entre les individus.

Etude des variables



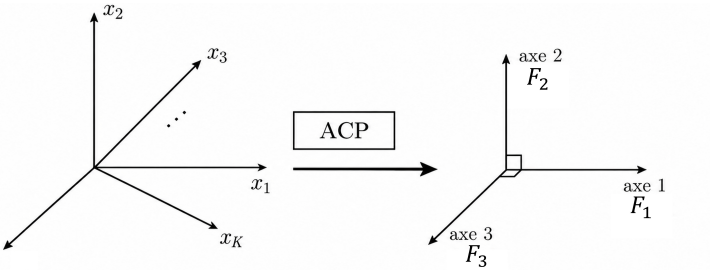
Chaque **variable** k est représentée par un point dans l'espace des individus $\mathbb{R}^I$.

On étude les liaisons entre les variables.

2. Étude des individus

Le nuage des individus N^I

On cherche une représentation des I individus $x_1, x_2, \ldots, x_I \in \mathbb{R}^K$ dans un sous-espace de dimension q, avec $q < K$ (en général $q = 2$ ou 3).



Nuage des individus N^I dans $\mathbf{R}^K$ (espace des variables)

Représentation dans un sous-espace de dimension q ($q = 2$ ou 3) (axes principaux)

Autrement dit, on cherche à construire q nouvelles variables, appelées **composantes principales**, qui sont des combinaisons linéaires des K variables initiales, tout en **conservant au mieux la dispersion du nuage des individus**.

Le nuage des individus N^I

On cherche une représentation du nuage des individus N^I dans un espace de dimension réduite, tout en conservant le maximum d'information possible.

Comment mesurer la qualité de cette représentation ?

Deux notions géométriques vont jouer un rôle essentiel :

Distance

Mesurer les ressemblances entre les individus.

Projection orthogonale

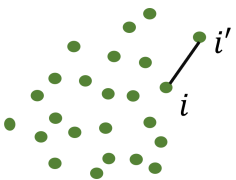
Représenter le nuage dans un espace de dimension réduite.

Ces deux notions permettront de rechercher une représentation aussi fidèle que possible du nuage N^I.

La distance entre deux individus

Dans le nuage N^I, chaque individu i est représenté par un point dans un espace de dimension K :

$$x_i = (x_{i1}, \ldots, x_{iK}) \in \mathbb{R}^K.$$



La **distance euclidienne** entre deux individus i et i' permet de mesurer leur proximité dans l'espace des variables.

$$d^2(i, i') = \sum_{k=1}^{K} (x_{ik} - x_{i'k})^2$$

Mais que se passe-t-il lorsque les variables sont exprimées dans des unités ou des échelles très différentes ?

La distance peut alors être fortement influencée par les variables ayant la plus grande dispersion.

$\Longrightarrow$ **Il faut rendre les variables comparables.**

Centrage – réduction des données

Lorsque les variables sont exprimées dans des unités ou des échelles différentes, elles ne contribuent pas de la même manière au calcul des distances.

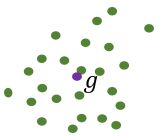
Pour rendre les variables **comparables**, chaque donnée x_{ik} est transformée en :

$$z_{ik} = \frac{x_{ik} - \bar{x}_k}{s_k}$$

où $\bar{x}_k$ est la **moyenne** de la variable k, et s_k est son **écart-type**.

$$\bar{x}_k = \frac{1}{I}\sum_{i=1}^{I} x_{ik}, \qquad s_k = \sqrt{\frac{1}{I}\sum_{i=1}^{I}(x_{ik} - \bar{x}_k)^2}.$$

Centrage



$$g = (\bar{x}_1, \ldots, \bar{x}_K) \xrightarrow{\text{centrage}} O$$

Le centre de gravité du nuage centré coïncide avec l'origine O.

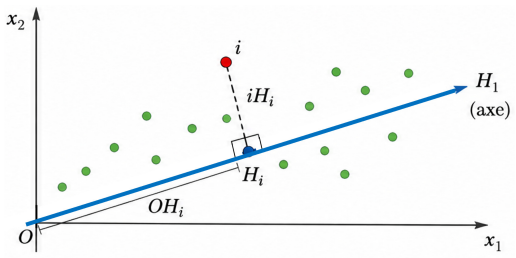
Réduction

$$\bar{z}_k = 0 \qquad \mathrm{Var}(z_k) = 1$$

Toutes les variables ont ainsi la même échelle de dispersion.

Ajustement du nuage des individus

L'objectif est de trouver un axe qui **déforme le moins possible** le nuage des individus N^I.



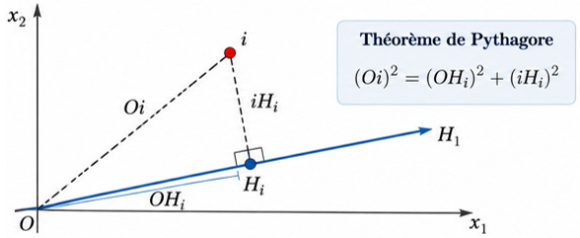
Pour chaque individu i :

- i est le point-individu dans $\mathbb{R}^K$;
- H_i est sa **projection orthogonale** sur l'axe ;
- iH_i mesure l'écart entre l'individu et sa représentation ;
- OH_i mesure la distance de la projection à l'origine O.

Un bon axe doit représenter au mieux la dispersion du nuage.

Ajustement du nuage des individus

Pour chaque individu i, la projection orthogonale sur l'axe forme un triangle rectangle.



Déformer le moins possible
L'axe recherché doit être aussi proche que possible des points du nuage.

Conserver le maximum de dispersion
Comme la distance Oi est fixée, cela revient à rendre la distance projetée OH_i aussi grande que possible.

$$\min \sum_{i=1}^{I} (iH_i)^2 \iff \max \sum_{i=1}^{I} (OH_i)^2$$

Cette dispersion sera mesurée par une quantité appelée inertie.

Inertie du nuage des individus

L'**inertie** mesure la dispersion globale du nuage des individus autour de son centre de gravité.

Inertie totale du nuage

$$\mathcal{I}(N^I) = \frac{1}{I}\sum_{i=1}^{I} d^2(i, O) = \frac{1}{I}\sum_{i=1}^{I}\sum_{k=1}^{K} z_{ik}^2$$

En regroupant les termes par variable :

$$\mathcal{I}(N^I) = \sum_{k=1}^{K} \underbrace{\left(\frac{1}{I}\sum_{i=1}^{I} z_{ik}^2\right)}_{\mathrm{Var}(z_k)}$$

Puisque les variables sont centrées-réduites,

$$\mathrm{Var}(z_k) = 1 \qquad \Longrightarrow \qquad \boxed{\mathcal{I}(N^I) = K}.$$

Formulation du premier axe principal

On cherche une direction qui représente au mieux la dispersion du nuage des individus.

Direction du premier axe

$$u_1 \in \mathbb{R}^K, \qquad u_1^\top u_1 = 1$$

La coordonnée de l'individu i sur cet axe est :

$$F_{i1} = z_i^\top u_1$$

Pour tous les individus :

$$F_1 = Z u_1$$

On choisit la direction u_1 qui maximise la variance des projections :

$$\max_{\|u_1\|=1} \mathrm{Var}(F_1)$$

De la covariance à la corrélation

Pour calculer $\mathrm{Var}(F_1)$, avec $F_1 = Zu_1$, on doit tenir compte des relations entre les variables.

Covariance

$$\mathrm{Cov}(X_k, X_{k'}) = \frac{1}{I}\sum_{i=1}^{I}(x_{ik} - \bar{x}_k)\cdot(x_{ik'} - \bar{x}_{k'})$$

Corrélation de Pearson

$$r_{kk'} = \frac{\mathrm{Cov}(X_k, X_{k'})}{s_k s_{k'}} = \frac{1}{I}\sum_{i=1}^{I}\frac{x_{ik} - \bar{x}_k}{s_k}\cdot\frac{x_{ik'} - \bar{x}_{k'}}{s_{k'}}$$

Comme les variables sont centrées-réduites, $z_{ik} = (x_{ik} - \bar{x}_k)/s_k$, on obtient :

$$\boxed{r_{kk'} = \frac{1}{I}\sum_{i=1}^{I} z_{ik} z_{ik'}}$$

Cette expression permet de passer des corrélations entre deux variables à leur écriture matricielle.

Matrice de corrélation

La structure des relations entre les variables centrées-réduites est résumée par la matrice de corrélation R.

Données centrées-réduites

$$Z = \begin{pmatrix} z_{11} & \cdots & z_{1K} \\ \vdots & \ddots & \vdots \\ z_{I1} & \cdots & z_{IK} \end{pmatrix}$$

$$\bar{z}_k = 0, \qquad \mathrm{Var}(z_k) = 1$$

Matrice de corrélation

$$\boxed{R = \frac{1}{I} Z^\top Z}$$

$$R = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1K} \\ r_{21} & 1 & \cdots & r_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ r_{K1} & r_{K2} & \cdots & 1 \end{pmatrix}$$

$$r_{kk'} = \mathrm{Corr}(z_k, z_{k'})$$

Comme $F_1 = Zu_1$,

$$\mathrm{Var}(F_1) = u_1^\top R u_1 \qquad \Longrightarrow \qquad \boxed{\max_{u_1^\top u_1 = 1} u_1^\top R u_1}$$

Le premier axe maximise l'inertie projetée.

Axes principaux : vecteurs et valeurs propres

Les directions principales sont les solutions du problème de maximisation de l'inertie projetée.

$$\max_{u^\top u=1} u^\top R u \quad \Longrightarrow \quad R u_s = \lambda_s u_s, \quad s = 1, \ldots, K$$

Vecteurs propres

$$u_1,\ u_2, \ldots, u_K$$

$$u_s^\top u_s = 1, \qquad u_s^\top u_{s'} = 0 \quad (s \neq s').$$

Les vecteurs propres u_s donnent les **directions des axes principaux**.
Les axes principaux sont deux à deux orthogonaux.

Valeurs propres

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_K \geq 0$$

$$\mathrm{Var}(F_s) = \lambda_s$$

La valeur propre λ_s mesure l'**inertie portée par l'axe** s.

Ainsi, λ_1 est associée au premier axe principal, dont la direction est donnée par u_1.

Inertie expliquée par les axes principaux

Chaque axe principal u_s est associé à une valeur propre λ_s, qui mesure **l'inertie portée par cet axe**.

Inertie totale

L'inertie totale du nuage se répartit entre les K axes principaux :

$$\mathcal{I}(N^I) = \sum_{s=1}^{K} \lambda_s$$

Or, pour les données centrées-réduites, nous avons montré que

$$\mathcal{I}(N^I) = K.$$

Ainsi,

$$\boxed{\sum_{s=1}^{K} \lambda_s = K}$$

Les valeurs propres répartissent l'inertie totale du nuage entre les axes principaux.

Inertie expliquée par les axes principaux

Inertie expliquée par l'axe s

La proportion d'inertie expliquée par l'axe s est :

$$\tau_s = \frac{\lambda_s}{\sum_{j=1}^{K} \lambda_j}$$

Dans le cas des données centrées-réduites, $\sum_{j=1}^{K} \lambda_j = K$, donc :

$$\tau_s = \frac{\lambda_s}{K}$$

soit, en pourcentage :

$$\text{Inertie expliquée (\%)} = 100 \times \frac{\lambda_s}{K}.$$

Plus λ_s est grande, plus l'axe u_s représente une part importante de la dispersion du nuage.

Choix du nombre d'axes

Pour réduire la dimension, on conserve les premiers axes de façon à représenter une part jugée suffisante de l'inertie totale.

- **Inertie expliquée cumulée**

  Pour les q premiers axes :

$$\tau_{1:q} = \sum_{s=1}^{q} \tau_s = \frac{\lambda_1 + \cdots + \lambda_q}{\sum_{s=1}^{K} \lambda_s}$$

  Les valeurs propres étant ordonnées :

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_K,$$

  les premiers axes sont ceux qui portent le plus d'inertie.

Exemple : $K = 4$

Supposons :

$$\lambda_1 = 2.4, \quad \lambda_2 = 1.0, \quad \lambda_3 = 0.4, \quad \lambda_4 = 0.2.$$

Alors :

$$\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 4.$$

Les deux premiers axes expliquent :

$$\tau_{1:2} = \frac{2.4 + 1.0}{4} = 0.85$$

85 % de l'inertie totale

Dans cet exemple, on peut ainsi passer de $\mathbb{R}^4$ à $\mathbb{R}^2$ en conservant 85 % de l'inertie du nuage.

Projection des individus sur les axes principaux

Une fois les q axes principaux retenus, chaque individu est **projeté** sur ces nouvelles directions.

Coordonnée sur l'axe s

Pour l'individu i, la coordonnée sur l'axe principal u_s est :

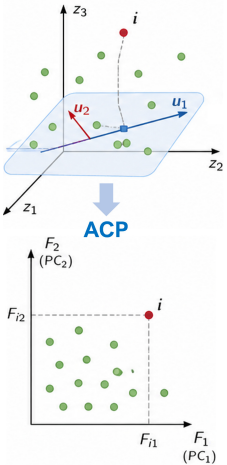
$$\boxed{F_{is} = z_i^\top u_s}$$

avec :

$$s = 1, \ldots, q.$$

Ainsi, pour les deux premiers axes :

$$F_{i1} = z_i^\top u_1, \qquad F_{i2} = z_i^\top u_2$$



Nouvelles coordonnées

Dans le cas $q = 2$, l'individu i est représenté par :

$$(F_{i1}, F_{i2})$$

dans le plan formé par les deux premiers axes principaux.

On passe donc de :

$$z_i \in \mathbb{R}^K$$

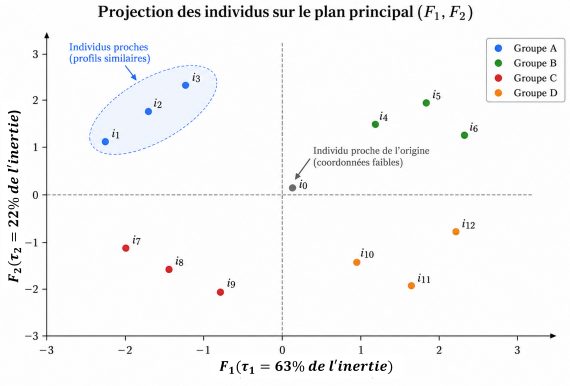
à :

$$\boxed{(F_{i1}, F_{i2}) \in \mathbb{R}^2}$$

Représentation des individus dans le plan principal

Une fois les deux premiers axes retenus, chaque individu i est représenté par ses **coordonnées principales** dans le plan (F_1, F_2) :

$$i \quad \longmapsto \quad (F_{i1}, F_{i2})$$



Lecture du plan principal

- Deux individus **proches** dans le plan ont des profils similaires sur les axes représentés.
- Deux individus **éloignés** présentent des profils différents sur ces axes.
- Un individu proche de **l'origine** a des coordonnées faibles sur les deux axes.
- La qualité globale du plan dépend de **l'inertie expliquée** par les axes retenus.

3. Étude des variables

Le nuage des variables

Après l'étude du nuage des individus N^I, on considère maintenant le **nuage des variables** N^K.

Une variable est un point de $\mathbb{R}^I$

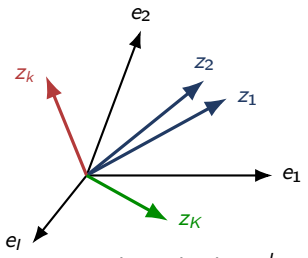
Pour la variable centrée-réduite k :

$$z_k = \begin{pmatrix} z_{1k} \\ z_{2k} \\ \vdots \\ z_{Ik} \end{pmatrix} \in \mathbb{R}^I.$$

Ainsi, les K variables forment le nuage :

$$\boxed{N^K = \{z_1, \ldots, z_K\} \subset \mathbb{R}^I}$$

Chaque point-variable est donc défini à partir de ses valeurs sur les I individus.



Espace des individus $\mathbb{R}^I$

Objectif : représenter ce nuage dans un espace de faible dimension tout en conservant au mieux les **relations entre les variables**.

La géométrie du nuage des variables traduit les corrélations entre les variables.

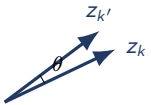
Angle entre deux variables et corrélation

Dans le nuage des variables N^K, la relation entre deux variables centrées-réduites z_k et $z_{k'}$ s'interprète par **l'angle** qu'elles forment.

$$\text{corr}(z_k, z_{k'}) = \frac{z_k^\top z_{k'}}{\|z_k\| \, \|z_{k'}\|} = \cos(\theta_{kk'})$$

$$\boxed{r_{kk'} = \cos(\theta_{kk'})}$$

Corrélation positive

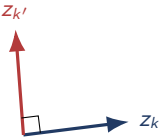


$\theta \simeq 0°$

$r_{kk'} \simeq +1$

Les deux variables évoluent dans le **même sens**.

Corrélation proche de zéro

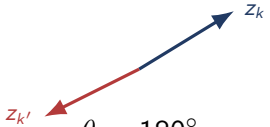


$\theta \simeq 90°$

$r_{kk'} \simeq 0$

Pas de **liaison linéaire** marquée.

Corrélation négative



$\theta \simeq 180°$

$r_{kk'} \simeq -1$

Les deux variables évoluent en **sens opposé**.

Ajustement du nuage des variables

On cherche maintenant à représenter le nuage des variables N^K dans le plan principal (F_1, F_2), en conservant au mieux **leurs relations avec les axes principaux**.

1. Variable initiale

La variable k est représentée par :

$$z_k = \begin{pmatrix} z_{1k} \\ z_{2k} \\ \vdots \\ z_{Ik} \end{pmatrix} \in \mathbb{R}^I.$$

Elle appartient au **nuage des variables** N^K.

$\Longrightarrow$

2. Relation avec l'axe F_s

La relation entre la variable k et la composante principale F_s est mesurée par :

$$\rho_{ks} = \text{corr}(z_k, F_s)$$

avec

$$-1 \leq \rho_{ks} \leq 1.$$

Comme $F_s = Zu_s$ et $Ru_s = \lambda_s u_s$, on obtient, pour $\lambda_s > 0$:

$$\boxed{\rho_{ks} = \sqrt{\lambda_s}\, u_{ks}}$$

où u_{ks} est la k-ième composante du vecteur propre u_s.

Ajustement du nuage des variables

3. Plan principal

Dans le plan (F_1, F_2), la variable k est représentée par :

$$(\rho_{k1}, \rho_{k2})$$

c'est-à-dire :

$$\boxed{(\text{corr}(z_k, F_1), \text{corr}(z_k, F_2))}$$

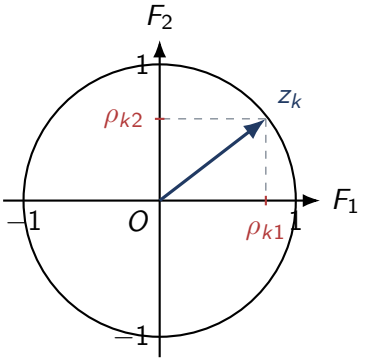
Les composantes principales étant non corrélées, la qualité de représentation de la variable dans le plan vérifie :

$$\boxed{\rho_{k1}^2 + \rho_{k2}^2 \leq 1}$$

Ainsi, les points-variables se situent à l'intérieur du cercle unité.

Cercle des corrélations

Pour représenter une variable k dans le plan principal (F_1, F_2), on utilise ses **corrélations avec les deux premières composantes principales**.



La variable k est représentée par le point :

$$\boxed{(\rho_{k1},\ \rho_{k2})}$$

avec

$$\rho_{k1} = \mathrm{corr}(z_k, F_1),$$
$$\rho_{k2} = \mathrm{corr}(z_k, F_2).$$

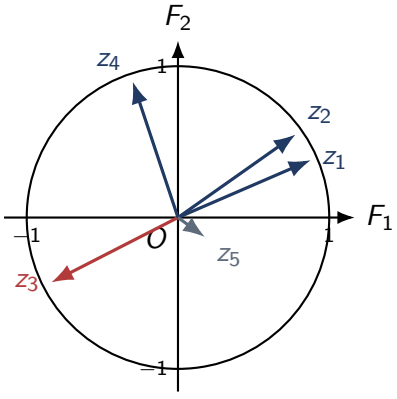
Ainsi :

$$\boxed{z_k \longmapsto (\rho_{k1}, \rho_{k2})}$$

La représentation simultanée des K variables dans le cercle unité constitue le cercle des corrélations

Interprétation du cercle des corrélations

La position des variables dans le cercle permet d'interpréter **les axes principaux** et **les relations entre les variables**.



Chaque flèche représente une variable initiale z_k.

Longueur de la flèche

Proche du cercle :

$\Rightarrow$ variable bien représentée

Proche de O :

$\Rightarrow$ variable mal représentée

Angle entre deux variables

- Petit angle : **corrélation positive**.
- Directions opposées : **corrélation négative**.
- Angle proche de 90° : **corrélation proche de zéro**.

Attention : cette interprétation est fiable lorsque les deux variables sont bien représentées dans le plan.

Qualité de représentation des variables

Pour une variable k, la qualité de représentation dans le plan (F_1, F_2) est mesurée par :

$$\boxed{\cos_k^2(F_1, F_2) = \rho_{k1}^2 + \rho_{k2}^2}$$

$$\cos_k^2 \simeq 1 \implies \textbf{variable bien représentée dans le plan}$$
$$\cos_k^2 \simeq 0 \implies \textbf{variable mal représentée dans le plan}$$

On interprète en priorité les variables bien représentées dans le plan principal.

Contribution des variables aux axes principaux

La qualité de représentation indique si une variable est bien représentée dans le plan principal. La contribution répond à une autre question :

Quelles variables participent le plus à la construction de l'axe F_s ?

Pour la variable k, la contribution à l'axe s est, pour $\lambda_s > 0$:

$$\text{ctr}_{ks} = \frac{\rho_{ks}^2}{\lambda_s} = u_{ks}^2$$

avec

$$\rho_{ks} = \text{corr}(z_k, F_s).$$

Une contribution élevée signifie que la variable participe fortement à la construction de l'axe.

Les contributions des K variables à un axe s vérifient :

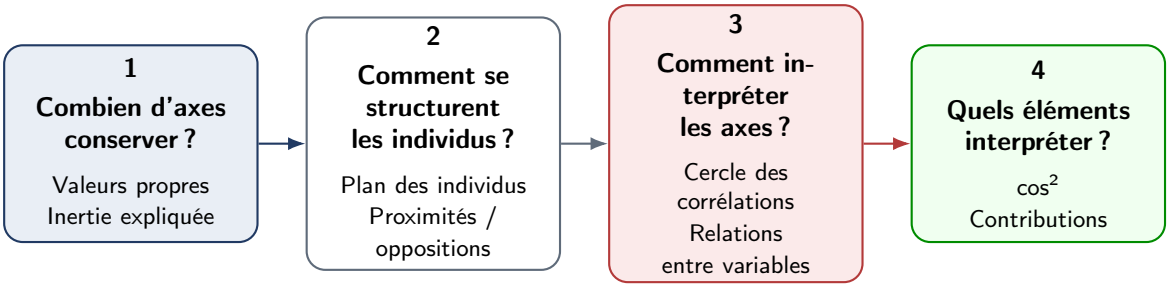
$$\sum_{k=1}^{K} \text{ctr}_{ks} = 1$$

soit 100 % si elles sont exprimées en pourcentage.

Les variables ayant les contributions les plus fortes permettent de caractériser l'axe principal.

Synthèse : comment interpréter une ACP ?

L'interprétation d'une ACP peut être organisée autour de **quatre questions principales**.



L'ACP réduit la dimension tout en permettant d'interpréter la structure des individus et les relations entre les variables.

4. Application