Travaux dirigés : Analyse en composantes principales

Exemple guidé – calculs à la main et vérification avec Python

Mines Saint-Étienne – Sciences des données

Année universitaire 2026–2027

Objectifs et consignes

- Travailler à partir d'un jeu de données de **4 individus** et **3 variables quantitatives**.
- Pour chaque étape : **calculer à la main**, **justifier**, puis **vérifier avec Python**.
- Interpréter les résultats, et pas seulement effectuer les calculs.
- Convention utilisée dans ce TD : variance calculée avec le facteur $1/I$.

Outils : Python, NumPy, pandas et matplotlib.

1. Présentation des données

Individu	X_1	X_2	X_3
A	1	4	1
B	2	3	3
C	3	2	3
D	4	1	1

Q1. Écrire la matrice X. Quelles sont ses dimensions $I \times K$?

Q2. Que représentent ses lignes et ses colonnes ?

Q3. Créer X avec NumPy et l'afficher sous forme de DataFrame pandas.

2. Centrage des données

$$\bar{x}_k = \frac{1}{I} \sum_{i=1}^{I} x_{ik}, \qquad x_{ik}^c = x_{ik} - \bar{x}_k.$$

Q4. Calculer les moyennes des variables X_1, X_2 et X_3.

Q5. Calculer les valeurs centrées de l'individu A, puis construire la matrice X_c.

Q6. Vérifier que la moyenne de chaque colonne de X_c est nulle.

Python. Utiliser `X.mean(axis=0)` et construire `X_centered`.

3. Réduction des données

$$s_k^2 = \frac{1}{I}\sum_{i=1}^{I}(x_{ik} - \bar{x}_k)^2, \qquad s_k = \sqrt{s_k^2}.$$

Q7. Calculer la variance et l'écart-type de chacune des trois variables.

Q8. Pourquoi est-il utile de réduire les variables avant une ACP normée ?

Python. Vérifier avec `X.std(axis=0, ddof=0)`.

4. Construction de la matrice centrée-réduite

$$z_{ik} = \frac{x_{ik} - \bar{x}_k}{s_k}.$$

Q10. Calculer les trois coordonnées centrées-réduites de A.

Q11. Construire la matrice Z complète.

Q12. Vérifier que chaque colonne de Z est de moyenne nulle et de variance égale à 1.

Python. Construire `Z = X_centered / stds` et vérifier les propriétés précédentes.

5. Matrice de corrélation

$$R = \frac{1}{I} Z^\top Z, \qquad r_{kk'} = \frac{1}{I} \sum_{i=1}^{I} z_{ik} z_{ik'}.$$

Q13. Quelles sont les dimensions de R ? Pourquoi utilise-t-on $Z^\top Z$?

Q14. Calculer r_{11}, r_{12}, r_{13} et r_{23}.

Q15. Compléter la matrice R et interpréter les corrélations entre X_1, X_2 et X_3.

Python. Calculer `R = Z.T @ Z / I`.

6. Valeurs propres et vecteurs propres

$$Ru_s = \lambda_s u_s, \qquad u_s^\top u_s = 1.$$

Q16. À l'aide de np.linalg.eigh(R), calculer les valeurs propres et les vecteurs propres de la matrice de corrélation R.

Q17. Classer les valeurs propres par ordre décroissant et réordonner les vecteurs propres correspondants.

Q18. Vérifier que chaque vecteur propre est de norme unitaire.

Q19. Vérifier l'orthogonalité des vecteurs propres.

7. Inertie expliquée et choix des axes

$$\mathcal{I}_{\text{totale}} = \sum_{s=1}^{K} \lambda_s, \qquad \tau_s = \frac{\lambda_s}{\sum_{j=1}^{K} \lambda_j}.$$

Q20. Calculer l'inertie totale. Retrouve-t-on K ?

Q21. Calculer le pourcentage d'inertie expliqué par chaque axe.

Q22. Calculer les pourcentages cumulés et proposer un nombre d'axes q à conserver.

Python. Construire un tableau des valeurs propres et des inerties expliquées ; tracer un diagramme en barres.

8. Coordonnées principales des individus

$$F_s = Zu_s, \qquad F = ZU_q.$$

Q23. Calculer les coordonnées de l'individu A sur les axes 1 et 2.

Q24. Calculer les coordonnées de B, C et D ; présenter le tableau des coordonnées factorielles.

Q25. Vérifier que $\mathrm{Var}(F_s) = \lambda_s$.

Python. Calculer les projections par produit matriciel.

9. Plan factoriel des individus

Q26. Tracer le nuage des individus dans le plan (F_1, F_2) ; identifier A, B, C et D.

Q27. Indiquer sur les axes les pourcentages d'inertie expliquée.

Q28. Quels individus sont proches ? Quels individus sont éloignés ?

Q29. Comment interpréter la position des individus par rapport à l'origine ?

Python. Utiliser `plt.scatter` et annoter les quatre points.

10. Corrélations entre variables et axes

$$\rho_{ks} = \mathrm{corr}(z_k, F_s) = \sqrt{\lambda_s}\, u_{ks}.$$

Q30. Calculer les corrélations de X_1, X_2 et X_3 avec F_1 et F_2.

Q31. Quelles variables caractérisent le premier axe ? Le deuxième ?

Q32. Quelle différence faites-vous entre une coordonnée d'individu et une corrélation variable–axe ?

Python. Construire le tableau des corrélations variable–composante.

11. Cercle des corrélations

Q33. Placer les trois variables dans le plan (F_1, F_2) à partir des corrélations calculées.

Q34. Tracer le cercle unité et interpréter les angles entre les flèches.

Q35. Que signifie une corrélation nulle ? Peut-on en déduire l'indépendance ?

Q36. Pourquoi faut-il tenir compte de la qualité de représentation pour interpréter un cercle des corrélations ?

Python. Tracer le cercle et les flèches avec matplotlib.

12. Qualité de représentation : $\cos^2$

$$\cos^2(X_k, F_s) = \rho_{ks}^2, \qquad \cos_k^2(F_1, F_2) = \rho_{k1}^2 + \rho_{k2}^2.$$

Q37. Calculer les $\cos^2$ de chaque variable sur les axes 1 et 2.

Q38. Calculer la qualité de représentation de chaque variable dans le plan (F_1, F_2).

Q39. Quelle question le $\cos^2$ permet-il de résoudre ?

Python. Vérifier les résultats à partir du tableau des corrélations.

13. Contributions des variables

$$\mathrm{ctr}_{ks} = \frac{\rho_{ks}^2}{\lambda_s} \quad (\lambda_s > 0).$$

Q40. Calculer les contributions des trois variables aux axes 1 et 2.

Q41. Vérifier que la somme des contributions vaut 100% pour chaque axe.

Q42. Comparer les contributions à la référence $100/K$. Quelles variables construisent principalement chaque axe ?

Q43. Expliquer la différence entre contribution et $\cos^2$.

Python. Tracer les contributions des variables à l'axe 1.

14. Synthèse et interprétation

Q44. Résumer les étapes de l'ACP depuis X jusqu'aux axes principaux.

Q45. Pourquoi deux axes suffisent-ils pour représenter ce jeu de données ?

Q46. Relier les résultats de la matrice de corrélation, du plan des individus et du cercle des corrélations.

Q47. En quelques phrases, expliquer ce que l'ACP nous apprend sur ces quatre individus et leurs trois variables.